

C'est une excellente réflexion, et vous touchez du doigt un problème très classique en Data Science : **le déséquilibre des classes (ou des caractéristiques)** et son impact sur l'apprentissage d'un modèle.

Cependant, votre conclusion n'est pas tout à fait exacte. Même si une caractéristique binaire affiche un **0** dans 90 % des cas, **sa présence peut être cruciale pour le modèle**.

Voici une explication claire et détaillée de pourquoi vous devriez (ou non) la garder, avec des exemples concrets.

1. Pourquoi une colonne remplie de 0 peut quand même être très puissante ?

En Machine Learning, une caractéristique peu fréquente mais très ciblée s'appelle une **caractéristique à forte valeur prédictive unilatérale**.

Prenons un exemple concret avec vos trois maladies :

Imaginons que votre dataset contient 100 images (33 de chaque maladie).

- La Rouille commune (Image 3) → renvoie toujours 0 .
- L'Helminthosporiose (Image 2) → renvoie toujours 0 .
- La Cercosporiose (Image 1) → est la seule à renvoyer 1 . Mais comme l'algorithme OpenCV n'est pas parfait, il ne la détecte que 4 fois sur 33.

Dans votre dataset, vous aurez donc **96 zéros** et seulement **4 uns**. C'est très déséquilibré.

Ce que le modèle (ex: un Arbre de Décision) va faire :

L'arbre de décision va adorer cette colonne, car elle crée une règle absolue :

"Si limite_par_nervures == 1, ALORS c'est la Cercosporiose à 100%."

Même si cette règle ne se déclenche que pour 4 plantes sur 100, le modèle a sécurisé 4 prédictions parfaites sans aucun effort. Pour les 96 autres, il utilisera simplement d'autres caractéristiques (comme la couleur ou la taille). En enlevant cette colonne, vous privez le modèle d'un "raccourci" mathématique infaillible.

2. Le cas où vous avez raison : La Variance Nulle

Il y a un cas précis où votre intuition est parfaitement correcte : si la caractéristique est à 0 sur **absolument toutes** les lignes de votre dataset (ou à 99.9%).

- Si vous avez 1000 images et que vous obtenez 1000 fois la valeur 0 .
- Dans ce cas, la variance de la colonne est de 0 .
- **Conséquence** : Elle n'apporte aucune information directionnelle. Pour le modèle, c'est un "bruit" inutile qui va consommer de la mémoire pour rien. Vous pouvez la supprimer (c'est ce qu'on appelle le *Zero Variance Feature Selection*).

3. Comment savoir concrètement si elle affecte votre modèle ?

Au lieu de deviner, vous pouvez le vérifier mathématiquement après avoir entraîné votre modèle (par exemple avec `scikit-learn` en Python).

Étape 1 : Regarder l'importance des caractéristiques (Feature Importance)

Les modèles comme Random Forest, XGBoost ou les Arbres de Décision possèdent un attribut après l'entraînement appelé `.feature_importances_`. Il vous donne le pourcentage d'influence de chaque colonne. Si votre colonne est proche de 0% , elle ne sert à rien. Si elle est à 3% ou 5% , elle aide le modèle.

Étape 2 : Faire un test de corrélation

Vous pouvez mesurer la corrélation entre votre colonne `limite_par_nervures` et votre colonne cible (la maladie). Même si le score est faible globalement, il peut être très élevé spécifiquement pour la classe *Cercosporiose*.

En résumé : Que devez-vous faire ?

1. **Gardez-la pour l'instant.** 2. Si le modèle l'utilise, même sur quelques lignes, cela améliorera la précision globale (notamment le *score de précision* de la classe minoritaire).
2. Si après analyse de la *Feature Importance*, vous voyez qu'elle a un score de 0, vous pourrez la supprimer proprement en phase d'optimisation de votre code.